

Azərbaycan dili üçün Nitq Tanıma Sistemi

Analitik Hesabat — Hissə C

AI Engineer Intern Texniki Tapşırıq

Təhvil tarixi: 04.05.2026

Qısa xülasə

Tapşırıq Azərbaycan dili üçün avtomatik nitq tanıma (ASR) sisteminin qurulmasını əhatə edir. İş üç hissəyə bölünür: baza tətbiqi (Hissə A), fine-tuning cəhdi (Hissə B) və analitik hesabat (Hissə C).

Nəticələrin Xülasəsi

Hissə A — Baza Modeli Nəticələri

İstifadə olunan model:

nijatzeynalov/wav2vec2-large-mms-1b-azerbaijani-common_voice15.0

Dataset: 14 əl ilə qeyd edilmiş Azərbaycan dili audio faylı (1.wav, ..., 14.wav)

Neticələr:

Ortalama WER: 29.01%

Ortalama CER: 6.63%

Ən Yaxşı 5 Nümunə

Ən Yaxşı 5 Nümunə:

Ref : mən avtomatik nitq tanıma sistemi hazırlayıram

Pred: mən avtomatik nitq tanıma sistemi hazırlayıram

WER : 0.00

Ref : proqramlaşdırma mənim üçün maraqlıdır

Pred: proqramlaşdırma mənim üçün maraqlıdır

WER : 0.00

Ref : maşın öyrənməsi çox güclü sahədir

Pred: maşın öyrənməsi çox güclü sahədir

WER : 0.00

Ref : mən tələbəyəm

Pred: mən tələbəyəm

WER : 0.00

Ref : süni intellekt insan nitqini analiz edə bilir

Pred: sun intellekt insan nitqini analiz edə bilir

WER : 0.14

Ən Pis 5 Nümunə

Ən Pis 5 Nümunə:

Ref : bu model müxtəlif səsləri tanımağa çalışır
Pred: bu model müxtəlif səsləri tanımğa salışır
WER : 0.33

Ref : mən data mühəndisliyi ilə məşğulam
Pred: mən dahata mühəndislii ilə məşğulam
WER : 0.40

Ref : bu model səsi mətnə çevirir
Pred: bu mode səsi mətnəd sevirik
WER : 0.60

Ref : mənim komputerim çox güclü işləyir
Pred: mənim kompüterim çox güclüşləyir
WER : 0.80

Ref : mənim ixtisasım süni intellekt mühəndisliyidir
Pred: mənin ixtisasım suyni intellekt müəndisi idir
WER : 0.80

Hissə B — Fine-Tuning Nəticələri

Dataset: tahmaz/azerbaijani-asr-fl (120 nümunə — 108 train, 12 test)

Mühit: Google Colab - T4 GPU (15 GB VRAM)

Model	WER	Fərq
Baseline (fine-tune əvvəli)	39.27%	—
Fine-tuned (2 epoch, 54 addım)	47.12%	+7.85% (pisləşdi)

Qeyd: WER-in artması az data (120 nümunə) və az epoch (2) ilə əlaqədardır. Training loss 1.02-dən 0.65-ə enib — model öyrənir, lakin 2 epoch kifayət etmir. Bu texniki cəhətdən düzgün qurulmuş pipeline-dır, nəticənin pisləşməsi resurs məhdudiyyətindən qaynaqlanır.

C1. Çətinliklər və Həllər

Texniki Problemlər

- Versiya uyğunsuzluğu: transformers 4.41 + accelerate 0.30 birlikdə işləmədi. clear_device_cache funksiyası köhnə accelerate-də yox idi. Həll: transformers -> 4.44.2 & accelerate -> 0.33.0 kombinasiyasına keçildi.

- VRAM dolması: wav2vec2-large-mms-1b modeli 3.86 GB-dır, T4-ün (15 GB) demək olar ki, hamısını yüklənmə zamanı istifadə edirdi. Həll: freeze_feature_encoder() + gradient_checkpointing + adafactor optimizer + fp16 tətbiq edildi.
- DataCollator xətası: processor.pad() funksiyasına labels (input_ids) verilirdi, o isə yalnız input_values gözləyir. Həll: labels üçün processor.tokenizer.pad() ayrıca çağırıldı.
- GPU aktivasiyası: fp16=True CPU-da xəta verir. Həll: use_gpu = torch.cuda.is_available() yoxlaması əlavə edildi.

Azərbaycan Dilinin ASR-ı Çətinləşdirən Xüsusiyyətləri

- Aqqlütinativ quruluş: Azərbaycan dili sözlərə çoxlu şəkilçi əlavə edir (məs: "hazırlayıram", "tanımağa"). Bu, söz lüğətini genişləndirir və modelin tanıması üçün çətin olur.
- Xüsusi hərflər: ə, ö, ü, ğ, ş, ç, ı hərfləri modelin tokenizer-ında düzgün idarə edilməlidir. Yanlış tokenizasiya birbaşa WER artımına səbəb olur.
- Az resurs: Azərbaycan dili üçün mövcud açıq ASR dataset və modellər ingilis dilinə nisbətən son dərəcə azdır, bu da baseline keyfiyyətini aşağı salır.
- Xarici sözlər: "speech recognition", "data" kimi ingilis sözləri Azərbaycan cümlələrindəki yeri modeli çaşdırır (4.wav-da WER: 0.29).

C2. Nəticələrin Təhlili

WER/CER Qiymətləndirməsi

Baza modelinin Hissə A üzrə nəticəsi: WER 29.01%, CER 6.63%.

Bu nəticə Azərbaycan dili üçün mövcud resurs məhdudiyyəti nəzərə alındıqda qəbul ediləndir. CER-in (6.63%) WER-dən (29.01%) xeyli aşağı olması göstərir ki, model hərfləri əsasən düzgün tanıyır, lakin söz sərhədlərini və bütöv sözləri bəzən səhv qruplaşdırır. Sadə, qısa cümlələrdə (9.wav, 10.wav, 11.wav, 13.wav) WER 0.00% — mükəmməl nəticədir.

Model Səhvlərinin Növləri

- Fonetik səhvlər: "süni" → "sun", "suyni"; "komputer" → "kompüter". Model bənzər səslənən variantları qarışdırır.
- Leksik birləşmə səhvləri: "güclü işləyir" → "güclüşləyir" — iki ayrı sözü birləşdirir. Bu CTC modelləri üçün tipik xətdir. (CTC - Connectionist Temporal Classification - zaman üzrə hizalanması bilinməyən ardıcıl məlumatlarda (məsələn, səs → mətn) girişlə çıxışı uyğunlaşdırmaq üçün istifadə olunan bir üsuldur və əsasən avtomatik nitq tanımada tətbiq olunur.)
- Xarici söz transliterasiyası: "speech recognition" → "spitç rəkoqnetion" — model ingilis sözlərini Azərbaycan fonetikasına ilə yazır.
- Söz parçalanması: "mühəndisliyidir" → "müəndisi idir" — uzun aqqlütinativ sözlər bölünür.

Audio Şərtlərinin Təsiri

- Daha yaxşı nəticə: Qısa, aydın tələffüz edilmiş cümlələr (9, 10, 11, 13-cü fayllar). Sakit mühit, mikrofondan optimal məsafə.
- Daha pis nəticə: Uzun, mürəkkəb sözlər (1, 2-ci fayllar). Xarici söz qarışıqlığı olan cümlələr (4-cü fayl). Sürətli tələffüz nəticəsində yaranan söz birləşmələri (8-ci fayl).

C3. Yaxşılaşdırma Yolları

Production-a Aparmaq üçün Lazım Olanlar

- Daha böyük, keyfiyyətli Azərbaycan dili dataseti (ən azı 100+ saat audio).
- Tam fine-tuning: bütün transformer qatlarını train etmək üçün A100/H100 GPU.
- Dil modeli (Language Model) integrasiyası: CTC çıxışını düzəltmək üçün n-gram və ya transformer LM əlavəsi.
- Streaming inferens: real vaxt tanıma üçün chunk-based audio emal.
- Docker konteynerizasiyası və REST API: production deployment üçün.

Daha Çox Resurs Olsaydı — Növbəti 3 Addım

Addım	Təsvir	Gözlənilən Nəticə
1	Tam fine-tuning: bütün model parametrlərini 1000+ nümunə üzərində A100-də train etmək	WER 15-20%-ə enə bilər
2	Azərbaycanca dil modeli (KenLM və ya GPT-2) ilə beam search dekodlaşdırma	WER 5-10% əlavə azalma
3	Data augmentation: səs sürəti, əks-səda, arxa plan küyü əlavəsi ilə dataset genişləndirilməsi	Modelin müxtəlif şərtlərə dözümlülüyü artır

Azərbaycan Dili ASR-ın Ən Böyük Problemi

Azərbaycan dili üçün ASR-ın ən böyük problemi, modeli yüksək keyfiyyətlə train etmək üçün lazım olan böyük həcmli, etiketlənmiş audio datasetinin olmamasıdır — bu isə mövcud modellərin aqqlütinativ söz quruluşunu düzgün öyrənə bilməməsinə səbəb olur.

Yekun

Bu layihədə Azərbaycan dili üçün tam ASR pipeline-ı qurmağa çalışdım. Hissə A-da dataset əvəzi 14 əl ilə qeyd edilmiş audio üzərində WER 29.01%, CER 6.63% nəticəsi göstərib. Hissə B-də Google Colab T4 GPU üzərində fine-tuning pipeline qurulub, VRAM məhdudiyyətlərini həll edən optimallaşdırmalar aparılıb. Fine-tuning nəticəsinin baseline-dan aşağı olmaması üçün daha çox data və epoch lazımdır, bu texniki xəta deyil, resurs məsələsidir.